
Rapport de projet S7 (2022-2023)

Modélisation de l'apparition et du développement de cancers du sang

Réalisé par :

Bilel HATMI

Alexandra KORTCHEMSKI

Thomas MIGLIASSO

Diego RUIZ PONSODA

Table des matières

I	Introduction	1
I	Contexte et objectif	1
II	Notre contribution	1
III	Structure du rapport	1
IV	L'homozygotie comme facteur déterminant du cancer	1
V	Acquisition de l'homozygotie	3
VI	Incorporation de l'homozygotie dans le modèle	3
VI.1	Description du modèle d'Hermange & al.	4
VI.2	Explication de la structure du code <i>Julia</i> du modèle purement hétérozygote	5
VI.3	Motivation de l'incorporation de l'homozygotie au modèle	5
VI.3.1	Définition des modèles stochastiques faisant intervenir l'homozygotie	6
VI.3.2	Explication du processus de simulation	6
VI.4	Présentation des résultats obtenus	7
VI.4.1	Présentation des résultats pour le modèle intégrant l'homozygotie	8
VII	Première approche : Calcul naïf de la loi des temps d'apparition des premières cellules homozygotes au cours de la phase déterministe	8
VIII	Deuxième approche pour le calcul de la loi de l'apparition de la première cellule homozygote . . .	11
VIII.1	Première détermination analytique	12
VIII.1.1	Notations	12
VIII.1.2	Premières hypothèses	12
VIII.1.3	Détermination de la loi de R_n	12
VIII.1.4	Détermination de la loi de T_n	13
VIII.1.5	Détermination de la loi de τ	14
VIII.2	Implémentation de la méthode	14
IX	Troisième approche : détermination du temps de première apparition d'une cellule homozygote via un modèle de branchement	16
IX.1	Explication du fonctionnement des processus de branchements	16
IX.2	Résultats sur les fonctions génératrices de moments	17
IX.3	Application des processus de branchement à notre cas d'utilisation	17
IX.3.1	Cadre de travail	17
IX.3.2	Présentation des notations et mise en équation	18
IX.3.3	Etude mathématique de la solution à notre problème	19
IX.3.4	Résolution du système	19
IX.4	Pistes d'améliorations pour cette modélisation	20
X	Conclusion et perspectives	20

Chapitre I

Introduction

I Contexte et objectif

Les syndromes myéloprolifératifs appartiennent au groupe des cancers du sang. Ils surviennent suite à l'acquisition d'une mutation (dite motrice) au niveau d'une cellule souche hématopoïétique. Ces cellules sont des cellules qui se différencient par la suite en cellules du sang. Ainsi, la mutation conduit à une surproduction de cellules du sang. Ces maladies sont très problématiques puisqu'elles ne sont détectées que suite à la survenue de symptômes mortels tels que des thromboses, accidents cardio-vasculaires. Toutefois, des études récentes montrent que les mutations responsables de ces cancers apparaissaient plusieurs années voire plusieurs décennies avant les symptômes. Concevoir des méthodes de dépistage précoce constitue désormais un enjeu crucial. Cela requiert de comprendre et de modéliser les mécanismes qui régissent l'expansion clonale des cellules mutées. Ces maladies étant rares et les expériences sur les patients, lourdes sur le plan économique, constituer des échantillons de données s'avère délicat. On s'appuie donc sur un modèle mathématique stochastique pour simuler l'évolution du nombre de cellules mutées. Actuellement un modèle a été élaboré en collaboration avec l'institut Gustave Roussy. Toutefois, ce modèle reste néanmoins simple et nécessite d'être complexifié.

II Notre contribution

Notre contribution ici se mesure dans la complexification du modèle. Le modèle actuel présenté dans l'article [3] ne considère que l'expansion clonale des cellules HSC mutées hétérozygotes. Or, suite à des phénomènes appelés recombinaisons homologues, des cellules HSC mutées hétérozygotes peuvent devenir homozygotes et donner naissance à un clone homozygote. L'article [7] fournit de plus non seulement des données patients de la fraction clonale en cellules hétérozygotes mais aussi celle des cellules homozygotes. Ainsi, la prise en compte de l'homozygotie dans le modèle permettrait de le rendre non seulement plus proche de la réalité mais aussi de voir estimer ses paramètres avec davantage de données expérimentales.

Ainsi, l'ensemble des travaux que nous avons menés ont été dans l'optique d'intégrer les cellules HSC homozygotes dans le modèle.

III Structure du rapport

Les Chapitres V et IV introduisent le contexte biologique des cellules homozygotes et présentent le phénomène de recombinaisons homologues. Le Chapitre VI introduit le modèle sur lequel nous avons travaillé et présente l'incorporation des cellules HSC homozygotes. Les Chapitres VII, VIII et IX s'intéressent à la détermination de la loi d'apparition des temps d'apparition des premières cellules homozygotes. Finalement, les conclusions et perspectives ouvertes par ce projet sont présentées.

IV L'homozygotie comme facteur déterminant du cancer

L'homozygotie est un état génétique dans lequel un organisme possède des allèles identiques à un locus spécifique sur les deux copies d'un chromosome. Dans une cellule somatique normale, chaque locus possède deux

allèles, un de chaque parent. Lorsque les deux allèles sont identiques, la cellule est homozygote à ce locus. L'homozygotie peut être acquise par des mutations génétiques ou par recombinaison homologue, et elle peut avoir un impact important sur le développement du cancer. Dans le cas du cancer, l'homozygotie peut se produire lorsqu'une cellule somatique normale acquiert des mutations dans les deux copies d'un gène spécifique, ce qui entraîne la perte de fonction de la protéine correspondante. Ce phénomène peut être causé par des mutations héréditaires ou par des mutations qui se produisent au cours de la vie de l'organisme.

L'homozygotie peut avoir un impact important sur le développement du cancer, car elle peut entraîner la perte de fonction des gènes suppresseurs de tumeurs. Les gènes suppresseurs de tumeurs sont responsables du maintien de l'intégrité du génome et de la prévention de la formation de tumeurs. Lorsque les deux copies d'un gène suppresseur de tumeur sont perdues ou inactivées, la cellule est incapable de contrôler sa croissance et sa division, ce qui peut entraîner la formation d'une tumeur.

Ce travail montre l'étude et modélisation d'un cancer affectant le gène JAK2. Ce gène participe dans la régulation de la reproduction et de la génération des cellules. Le gène JAK2 est responsable de l'envoi de signaux dans les cellules pour favoriser la croissance cellulaire et contribue à contrôler le nombre de globules rouges, de globules blancs et de plaquettes qui sont fabriqués dans la moelle osseuse. Les mutations dans le gène JAK2 apparaissent souvent dans deux des types les plus courants de néoplasmes myéloprolifératifs (NMP), le *polycythemia vera* (PV) et le *essential thrombocythemia* (ET). De même, l'homozygotie apparaît fréquemment dans les cas de PV et d'ET avec la mutation JAK2V617F [1] [2]. La figure ci-dessous I.1 montre la présence et l'importance de l'homozygotie dans les NPM chez neuf patients.




FIGURE I.1 – Modeling JAK2V617F clonal architecture in PV patients [2]

Étant donné l'importance et la fréquence de l'apparition de l'homozygotie dans les cas de PMN, l'incorporation de ce phénomène dans la modélisation du développement de la PMN permet de se rapprocher significativement du développement réel de la maladie. De plus, lors de l'estimation des paramètres du modèle, cette complexification permet d'utiliser les données d'un plus grand nombre de patients, ce qui améliore le modèle.

V Acquisition de l'homozygotie

Bien qu'il existe plusieurs mécanismes pour acquérir l'homozygotie, les travaux présentés ici se concentrent sur la recombinaison mitotique, qui se produit à un taux estimé à 1% des divisions cellulaires somatiques [6]. La recombinaison mitotique est un mécanisme par lequel du matériel génétique peut être échangé entre des chromosomes non homologues pendant la division cellulaire. Ce processus peut entraîner l'homozygotie d'une mutation auparavant hétérozygote, et on pense qu'il se produit à une fréquence plus élevée dans certains types de cellules et organismes. L'image ci-dessous I.2 montre le processus d'acquisition de l'homozygotie.

L'image montre une reproduction mitotique normale au milieu et deux formes de perte d'hétérozygotie (LOH). Comme on le voit, les principaux mécanismes sont la recombinaison mitotique (illustrée ci-dessous) et la perte d'un segment chromosomique. Dans le cas de la recombinaison mitotique, on obtient une cellule de type sauvage et une cellule mutée homozygote. Pour la cellule mutée, l'homozygotie signifie des taux de reproduction et de mutation plus élevés. Dans le cas ci-dessus, la perte d'un gène sain peut impliquer que seul le gène muté est disponible pour les processus cellulaires. Dans le cas d'un gène muté récessif, cela sera crucial car il ne le sera plus.

Normalement, le croisement ou la recombinaison mitotique se produit pendant la réparation des cellules. Cela se produit lorsque des doubles brins d'ADN sont cassés pour être réparés. La recombinaison se produit lorsqu'après avoir été réparés, ils ne sont pas joints à leur extrémité précédente, créant ainsi un événement de crossover. La recombinaison mitotique, l'acquisition de mutations et la perte de brins d'ADN sont souvent provoquées par des agents tels que les radiations ou d'autres facteurs externes.




FIGURE I.2 – Principaux mécanismes à l'origine de l'homozygotie. [5]

L'un des principaux problèmes rencontrés lors du développement de ce travail a été de trouver des valeurs numériques pour modéliser ce phénomène, ce qui a conduit à plusieurs questions. Quel est le taux de recombinaison mitotique ? Quelle est la probabilité qu'elle affecte un brin d'une certaine longueur ? Comment le fait d'avoir déjà une mutation affecte-t-il ce mécanisme ?

VI Incorporation de l'homozygotie dans le modèle

Cette section a pour objet l'explication de l'intégration de l'homozygotie dans le modèle présenté par Hermange & al [3].

Cette section débute par une succincte description du modèle tel qu'il est présent dans [3] puis motive l'incorporation de l'homozygotie au modèle. Enfin, la méthode d'implémentation est détaillée et les résultats obtenus présentés.

VI.1 Description du modèle d'Hermange & al.

Le modèle proposé vise à simuler une expansion clonale débutant à partir d'une seule cellule HSC mutée. On suppose que le nombre de cellules wild-type demeure fixe au cours du temps, plaçant ce modèle dans des conditions dites homéostatiques. On note T_0 l'âge d'acquisition de la mutation. Celle-ci survient ou bien pendant l'embryogénèse ou bien après la naissance et est dans ce cas modélisée par une loi exponentielle de paramètre λ .

Au cours du temps, les cellules HSC se divisent avec un taux α . Mathématiquement, le temps qui s'écoule entre deux divisions est modélisé par une loi exponentielle de paramètre α .

Trois mécanismes de division sont habituellement considérés pour des cellules HSC. Premièrement, une cellule HSC peut se diviser de manière différenciée en deux cellules différenciées avec une probabilité p_0 . Deuxièmement, une cellule HSC peut se diviser de manière asymétrique avec une probabilité p_1 , donnant ainsi naissance une cellule HSC et une cellule différenciée. Enfin, une cellule HSC peut se diviser de manière symétrique en deux cellules souches avec une probabilité $p_2 = 1 - p_0 - p_1$. Ces trois mécanismes peuvent être visualisés sur la figure I.3.

Pour des cellules wild-type, $p_2 - p_0 = 0$. Au contraire, pour des cellules HSC mutées, on note $\Delta = p_2 - p_0 > 0$ l'avantage prolifératif qui leur est conféré par la mutation. En effet, dans ce cas, les divisions symétriques sont plus probables que les divisions différenciées, conduisant à une prolifération importante d'un clone de cellules HSC mutées. On infère également $q = \frac{p_0}{p_2}$ la probabilité qu'un clone mutant s'éteigne.




FIGURE I.3 – Illustration des trois types de division ; différenciée, symétrique et asymétrique. Image tirée de l'article [3].

Le but du modèle est de pouvoir suivre le nombre de cellules HSC mutées au cours du temps noté $N(t)$. Les divisions successives et la prolifération résultante sont modélisées par un processus stochastique qui peut être décrit comme une chaîne de Markov à temps continu.

Toutefois, plus le nombre de cellules HSC mutées devient important, plus la probabilité qu'une cellule HSC mutée se divise à un instant t augmente. Ainsi, le pas de temps de la simulation se réduit au fur et à mesure que celle-ci avance. Il est donc nécessaire de passer à un modèle déterministe approximant correctement le comportement du processus stochastique à partir d'un certain nombre de cellules HSC mutées. Il s'agit de trouver un compromis entre la grossièreté de l'approximation et la rapidité de l'exécution de la simulation. La valeur de $N(t) = 2000$ est ainsi adoptée comme "seuil déterministe" dans ce modèle.

L'idée va donc être de commencer par simuler une expansion stochastique à partir d'une unique cellule HSC mutée jusqu'à ce que le nombre de 2000 cellules HSC mutées soit atteint (si le clone ne s'éteint pas avant), avant de passer à un modèle déterministe.

Le modèle déterministe utilisé indique que

$$N(t) = N_0 \exp((t - t_0)\alpha\delta)$$

où N_0 désigne le nombre de cellules HSC mutées en t_0 , date d'atteinte du seuil déterministe. Les paramètres α et δ ont été introduits précédemment.

VI.2 Explication de la structure du code *Julia* du modèle purement hétérozygote

Dans ce paragraphe, plus de détails sont fournis quant à l'implémentation du modèle sus-décrit grâce au package *MarkovProcesses*.

Dans le modèle de Hermange & al [3], il s'agit d'abord de définir le modèle stochastique d'expansion sous la forme des trois équations de réaction décrites précédemment en précisant leurs taux de réaction respectifs comme montré sur la figure I.4.

```
invasion = @network_model begin
    sym: (HSC => 2HSC, alpha*p2*HSC) #Symmetrical divisions
    asym: (HSC => 1HSC + abs, alpha*(1.0-p2-p0)*HSC) #asymmetrical divisions
    diff: (HSC => 0, alpha*p0*HSC*(1.0+lambda-lambda+ind_app-ind_app)) #differentiated divisions
end "Process for mutated stem cells"
```

FIGURE I.4 – Définition du modèle stochastique dans le modèle purement hétérozygote. Le type de division est précisé en début de ligne, puis la réaction est écrite, et enfin le taux est indiqué. "abs" désigne un état absorbant non suivi puisque seule la quantité de cellules HSC mutées nous intéresse.

On précise ensuite que le modèle démarre avec une cellule HSC mutée, un temps maximal de simulation de 100 ans ainsi que le critère d'arrêt de la simulation qui est l'atteinte de 2000 cellules HSC mutées.

Les paramètres de simulation sont ensuite fixés : $\alpha = \frac{1}{30}$, $p_0 = 0.17$, $p_2 = 0.2$.

Une fois l'expansion stochastique terminée, le modèle déterministe prend le relais et on obtient en fin de simulation un vecteur contenant le nombre de cellules HSC mutées à chaque instant. Plus précisément, on obtient le nombre de cellules HSC mutées chaque jour de la première année puis une fois par an jusqu'à la centième année. Ce détail est assez important et posera quelques difficultés dans l'implémentation du modèle intégrant l'homozygotie.

Du nombre de cellules HSC mutées au cours du temps, on déduit également l'évolution de la fraction clonale au cours du temps à l'aide de la formule suivante :

$$\eta(t) = \frac{(1 - \delta)N(t)}{(1 - \delta)N(T) + N_{WT}}$$

Ces deux trajectoires peuvent ensuite être visualisées graphiquement comme illustré sur les figures I.5 and I.6.




FIGURE I.5 – Fraction clonale de cellules HSC hétérozygotes mutées au cours du temps

Les résultats de ces simulations ont ensuite vocation à être comparés avec des données patients hétérozygotes, notamment fournis par l'article [7] afin de procéder à une estimation des paramètres ici pris fixes.

VI.3 Motivation de l'incorporation de l'homozygotie au modèle

Les données patients mentionnées précédemment tirées de l'article de William & al. [7] et comportent non seulement des clones hétérozygotes mais également des clones homozygotes. L'incorporation de l'homozygotie




FIGURE I.6 – Évolution du nombre de cellules HSC hétérozygotes mutées au cours du temps au cours de la première année où celui-ci est régi par le modèle stochastique.

au modèle permettrait donc d'exploiter avec davantage de précision et de finesse les données patients dont nous disposons.

Comme expliqué en introduction, l'homozygotie apparaît le plus couramment suite à une recombinaison homologue entre deux cellules hétérozygotes HSC mutées. On introduit donc un paramètre γ traduisant la probabilité pour une cellule HSC mutée hétérozygote de devenir homozygote.

VI.3.1 Définition des modèles stochastiques faisant intervenir l'homozygotie

Il s'agit donc de proposer un modèle stochastique faisant intervenir à la fois les cellules HSC hétérozygotes et homozygotes du fait du mécanisme de simulation qui sera développé ensuite.

D'avantage de réactions sont ainsi envisagées. D'abord, une cellule HSC hétérozygote mutée peut se diviser comme précédemment de manière différenciée, asymétrique ou symétrique sans qu'aucune recombinaison homologue ne s'effectue. Dans ce cas là, les taux de réaction sont similaires au cas hétérozygote pur ; ils sont seulement multipliés par $1 - \gamma$. On obtient ainsi les 3 premières réactions.

Il en va exactement pour les mécanismes de division d'une cellule HSC mutée homozygote auxquels on assigne les probabilités q_0 et q_2 . Les taux de réaction sont dans ce cas là les mêmes que dans le cas hétérozygote pur, seulement p_0 est remplacé par q_0 et p_2 par q_2 . On obtient ainsi 3 réactions supplémentaires.

Enfin, dans le cas d'une recombinaison homologue, on part d'une cellule HSC hétérozygote mutée pour laquelle on distingue les trois processus de division. Ou bien elle se divise de manière différenciée auquel cas on obtient des cellules différenciées dont l'une bien qu'homozygote ne nous intéressent pas. Ou bien de manière asymétrique auquel cas on obtient dans la moitié des cas une cellule HSC mutée homozygote et une cellule différenciée hétérozygote et dans l'autre moitié une cellule HSC qui n'est plus mutée et une cellule différenciée homozygote (qui ne nous intéresse pas). Ou bien enfin de manière symétrique pour donner une cellule HSC homozygote mutée et une cellule souche hétérozygote. Les taux de réaction sont alors ceux du cas hétérozygote pur multipliés par γ . On obtient ainsi 3 réactions de plus.

Ce modèle peut être visualisé sur la figure I.7.

On construit également un second modèle stochastique réservé aux cellules homozygotes, sur le modèle du modèle hétérozygote pur, en remplaçant p_0 et p_2 par q_0 et q_2 . Ce modèle peut être visualisé sur la figure I.8.

VI.3.2 Explication du processus de simulation

La structure du code est la suivante :

- Simulation stochastique du modèle combinant les cellules HSC hétérozygotes et homozygotes mutées. Elle débute avec une cellule HSC hétérozygote mutée. Elle s'arrête lorsque 2000 cellules HSC sont atteintes. En pratique, aucune cellule HSC homozygote n'apparaît pendant cette phase car la probabilité d'apparition est faible.
- Simulation du modèle déterministe pour les cellules HSC hétérozygotes mutées.

```

invasion = @network_model begin
  sym_het_without_hom : (HSC_het => 2HSC_het, p2*alpha*(1-gamma)*HSC_het)
  asym_het_without_hom : (HSC_het => 1HSC_het + abs, alpha*(1-gamma)*(1.0-p2-p0)*HSC_het)
  diff_het_without_hom : (HSC_het => 0, alpha*(1-gamma)*p0*HSC_het*(1.0+lambda-lambda+ind_app-ind_app))
  sym_het_with_hom : (HSC_het => abs + 1HSC_hom, p2*alpha*gamma*HSC_het)
  asym_het_with_hom : (HSC_het => 1HSC_hom + abs, alpha*gamma*(1.0-p2-p0)*HSC_het*0.5)
  diff_het_with_hom : (HSC_het => 0, alpha*gamma*p0*HSC_het*(1.0+lambda-lambda+ind_app-ind_app))
  sym_hom : (HSC_hom => 2HSC_hom, alpha*q2*HSC_hom)
  asym_hom : (HSC_hom => 1HSC_hom + abs, alpha*(1.0-q2-q0)*HSC_hom)
  asym_diff : (HSC_hom => 0, alpha*q0*HSC_hom*(1.0+lambda-lambda+ind_app-ind_app))
end

```

FIGURE I.7 – Définition du modèle stochastique dans le modèle incorporant l’homozygotie. Le type de division est précisé en début de ligne, puis la réaction est écrite, et enfin le taux est indiqué. Les trois premières réactions caractérisent les divisions de cellules hétérozygotes sans recombinaison homologe. Les trois suivantes désignent les divisions de cellules hétérozygotes précédées d’une recombinaison homologe. Les trois dernières correspondent aux divisions des cellules homozygotes.

```

invasion_homozygous = @network_model begin
  sym_hom : (HSC_hom => 2HSC_hom, alpha*q2*HSC_hom) #Symmetrical division of Homozygous cells
  asym_hom : (HSC_hom => 1HSC_hom + abs, alpha*(1.0-q2-q0)*HSC_hom) #Asymmetrical division of Homozygous cells
  asym_diff : (HSC_hom => 0, alpha*q0*HSC_hom*(1.0+lambda-lambda+ind_app-ind_app)) #Differentiated division of Homozygous cells
end

```

FIGURE I.8 – Définition du modèle stochastique dans le modèle purement homozygote.

- Détermination des temps d’apparition des cellules HSC homozygotes mutées apparues pendant la phase déterministe des hétérozygotes.
- Simulation stochastique les uns après les autres des clones homozygotes apparus jusqu’à en trouver un qui ne s’éteint pas. On note $t_{\text{hom stoch}}$ le temps d’atteinte du critère d’arrêt de 2000 cellules HSC homozygotes mutées.
- Simulation stochastique des clones homozygotes dont les temps d’apparition sont inférieurs à $t_{\text{hom stoch}}$.
- Récupération des nombres de cellules HSC hétérozygotes et homozygotes au cours du temps, des temps d’apparition des clones qui ne se sont pas éteints.

L’idée de ne considérer l’expansion que des clones qui apparaissent avant $t_{\text{hom stoch}}$ vient du fait que lorsqu’un clone homozygote commence à s’expandre de manière déterministe, l’apparition d’une cellule homozygote supplémentaire ne changerait rien à la dynamique.

Le calcul des temps d’apparition des cellules HSC homozygotes mutées est complexe et fait l’objet de la section suivante.

Un obstacle rencontré est le choix de discrétisation du temps. En effet, comme dit précédemment, la discrétisation est d’un point tous les jours pendant une année puis d’un point toutes les années jusqu’à 100 ans. Toutefois, si cela ne pose pas problème pour un processus débutant avec une cellule HSC hétérozygote mutée, c’est problématique pour l’expansion à partir d’une cellule HSC homozygote apparaissant après la première année. En effet, le processus stochastique est caractérisé par ses fluctuations rapides et nécessite donc une discrétisation importante afin d’avoir un sens.

Discrétiser sur l’ensemble des 100 années n’est pas envisageable car la simulation ne tourne plus en un temps raisonnable. La solution apportée est donc de créer un vecteur discrétisé avec un point tous les jours pendant 100 ans et de le remplir a posteriori avec les différents clones homozygotes en remplissant pour chacun précisément les 365 jours suivant leur temps d’apparition puis en mettant la même valeur tout au long de l’année pour les années restantes.

La dynamique attendue peut-être visualisée sur la figure I.9.

VI.4 Présentation des résultats obtenus

On présente ici le résultat de simulations du modèle incorporant l’homozygotie où les temps d’apparition des cellules homozygotes ne suivent pas les lois d’apparition réelles mais qui apparaissent plutôt tous les 500 jours. En effet, les lois réelles ne sont pas encore implémentables.

D’abord, on retrouve l’expansion du clone hétérozygote sur les figures I.12 et I.13.

L’expansion des clones homozygotes peut être visualisée sur les figures I.10 ainsi que I.11.

Enfin, l’expansion du nombre total de cellules HSC homozygotes mutées peut être visualisée sur les figures I.10 et I.11.




FIGURE I.9 – Dynamique d'expansion attendue pour le modèle incorporant l'homozygotie.

VI.4.1 Présentation des résultats pour le modèle intégrant l'homozygotie




FIGURE I.10 – Expansion clonale stochastique de trois clones homozygotes. Ils sont représentés ici comme tous issus de 0 pour une question d'échelle afin de permettre une meilleure visualisation mais ils n'apparaissent pas en même temps dans la simulation.

VII Première approche : Calcul naïf de la loi des temps d'apparition des premières cellules homozygotes au cours de la phase déterministe

Comme vu dans la section précédente, il est nécessaire de savoir déterminer les instants d'apparition des k premières cellules homozygotes suite à des recombinaisons homologues.

On se donne donc pour objectif ici de déterminer la loi de la variable aléatoire T_k modélisant le temps d'apparition de la k -ième cellule homozygote au cours de la phase déterministe, survenant suite à une recombinaison homologue.

Le comportement attendu du fait du modèle est l'apparition de plus en plus rapprochée de quelques cellules homozygotes (au plus une dizaine) au cours du temps d'étude. En effet, plus les cellules HSC hétérozygotes mutées sont nombreuses, plus la probabilité qu'une recombinaison homologue survienne sur l'une d'entre elles à un instant donné est élevée.

On commence par étudier le cas $k = 1$.




FIGURE I.11 – Expansion clonale de trois clones homozygotes au cours de 8000 jours. La phase stochastique discrétisée précisément pendant 365 jours peut-être remarquée en début de dynamique. Elle continue ensuite avec une moins bonne précision temporelle.




FIGURE I.12 – Nombre de cellules hétérozygotes mutées au cours du temps pendant 100 ans.

On se place entre deux instants t et $t + dt$. On cherche la probabilité qu'exactly une cellule homozygote apparaisse entre t et $t + dt$. On note D_n la variable aléatoire modélisant le temps entre deux divisions pour une cellule HSC hétérozygote donnée. D_n suit une loi exponentielle de paramètre α .

On note A_{hom} l'évènement "exactement une recombinaison homologe à l'instant t survient", et $A_{\emptyset avant, t}$ l'évènement "aucune recombinaison homologe n'est survenue avant l'instant t ".

On cherche donc à déterminer :

$$\mathbb{P}\left(\bigcup_{k=1}^{N(t)} A_{hom} \cap A_{\emptyset \text{ hom avant } t}\right) = N(t) \times \mathbb{P}(A_{hom} \cap A_{\emptyset \text{ hom avant } t})$$

On réécrit :

$$\mathbb{P}(A_{hom} \cap A_{\emptyset \text{ hom avant } t}) = \mathbb{P}(A_{hom} | A_{\emptyset \text{ hom avant } t}) \times \mathbb{P}(A_{\emptyset \text{ hom avant } t})$$

à l'aide de probabilités conditionnelles.

D'abord,




FIGURE I.13 – Nombre de cellules homozygotes mutées au cours du temps pendant 100 ans.




FIGURE I.14 – Évolution de la fraction clonale des cellules hétérozygotes mutées au cours du temps pendant 100 ans.

$$\begin{aligned}
 \mathbb{P}(A_{\emptyset \text{ hom avant } t}) &= \prod_{k=1}^{N(t)} \mathbb{P}(\text{pas de recombinaison homologue sachant qu'une division} \\
 &\quad \text{se produit}) \mathbb{P}(\text{une division se produit}) \\
 &= \prod_{k=1}^{N(t)} \int_{t'=0}^{t'=t} (1 - \gamma) \times \mathbb{P}(D_k \in [t', t' + dt']) dt' \\
 &= (1 - \gamma)^{N(t)} \left(\int_0^t \alpha e^{-\alpha t'} dt' \right)^{N(t)} \\
 &= (1 - \gamma)^{N(t)} (1 - e^{-\alpha t})^{N(t)}
 \end{aligned}$$

Ensuite,

$$\mathbb{P}(A_{\text{hom}} | A_{\emptyset \text{ hom avant } t}) = \gamma \mathbb{P}(D_k \in [t, t+dt]) \gamma \times \prod_{k=1}^{N(t)-1} \mathbb{P}(\text{pas de recombinaison homologue sachant qu'une division se produit})$$




FIGURE I.15 – Évolution de la fraction clonale des cellules homozygotes mutées au cours du temps pendant 100 ans.

Ainsi,

$$f_{T1}(t) = N(t) \times \gamma \times (1 - \gamma)^{2N(t)-1} \alpha^{N(t)} (1 - e^{-\alpha t})^{N(t)} \times e^{-\alpha t N(t)}$$

Pour $N_0 = 1$, en renormalisant la densité, on obtient des résultats qui semblent plausibles comme présenté sur la figure I.16. Toutefois, pour $N_0 = 2000$, début fixé de la phase déterministe, la densité est si faible que la renormalisation n'est pas possible et le modèle tombe en défaut.




FIGURE I.16 – Densité de probabilité du temps d'apparition de la première cellules homozygote

VIII Deuxième approche pour le calcul de la loi de l'apparition de la première cellule homozygote

Compte tenu des hypothèses du modèle présenté par Hermange & al. dans [3] qui sont fortes, il est difficile d'établir des analogies avec des processus de branchement déjà existants pour déterminer la loi de la première division homzygote.

VIII.1 Première détermination analytique

Dans cette section, nous mettons en oeuvre une deuxième méthode visant à établir à la main la loi d'apparition de la première division homozygote en partant rigoureusement des hypothèses du modèle présenté par Hermange & al. dans [3].

VIII.1.1 Notations

Dans toute la section, on note :

- $(X_n)_{n \in \mathbb{N}}$ un processus i.i.d qui caractérise la nature symétrique, asymétrique ou différenciée de la n-ième division. La loi de ce processus est donc déterminée par :

$$\forall n \in \mathbb{N}, \mathbb{P}(X_n = 1) = p_2$$

$$\forall n \in \mathbb{N}, \mathbb{P}(X_n = -1) = p_0$$

$$\forall n \in \mathbb{N}, \mathbb{P}(X_n = 0) = p_1 = 1 - p_2 - p_0$$

- $(S_n)_{n \in \mathbb{N}}$ défini par $\forall n \geq 1, S_n = \sum_{k=1}^n X_k$ qui représente la marche aléatoire associée au processus $(X_n)_{n \in \mathbb{N}}$.
- $D = \inf\{n \geq 1, S_n = 0\}$ qui est un temps d'arrêt représentant la durée "biologique" du processus stochastique.
- $(R_n)_{n \in \mathbb{N}}$ le processus qui compte le nombre de cellules HSC à l'issue de la n-ième division. On a immédiatement que

$$\forall n \geq 1, R_n = S_{n \wedge D} = S_n I_{D \geq n}$$

- $(H_n)_{n \in \mathbb{N}}$ un processus i.i.d qui caractérise la nature homozygote de la n-ième division. Les éléments de ce processus suivent une loi de Bernoulli de paramètre γ
- $(D_n)_{n \in \mathbb{N}}$, la durée qu'il faut attendre pour passer de la n-ième à la (n+1)-ième division
- $(T_n)_{n \in \mathbb{N}}$ défini par $\forall n \geq 1, T_n = \sum_{k=1}^n D_k$, qui représente le temps qu'il faut attendre pour la (n+1)-ième division depuis l'apparition de la première cellule mutée
- $(N_t)_{t \in \mathbb{R}}$ un processus continu qui compte le nombre de division jusqu'à l'instant t .
- $N_t = \inf\{t \geq 0, H_n = 0\}$, le nombre de division qu'il faut réaliser pour aboutir à la première homozygotie
- $\tau = \inf\{t \geq 0, N_t = N_t\}$, le temps d'apparition de la première homozygotie.

Cette section a pour objectif de déterminer la loi de τ

VIII.1.2 Premières hypothèses

- L'apparition d'une homozygotie lors de la n-ième division est supposée indépendante du temps parcouru pour aboutir à cette n-ième division. Autrement dit, pour tout $n \in \mathbb{N}$, H_n est indépendante de T_n
- La dernière hypothèse sera très forte. Il s'agit de supposer que D est presque sûrement infini. Autrement dit, cela revient à considérer l'extinction de la prolifération comme un événement négligeable. Dès lors, $I_{D \geq n} = 1$, presque sûrement, puis $\forall n \geq 1, R_n = S_n$ p.s

H1

$$\forall n \in \mathbb{N}, H_n \perp T_n$$

H2

$$\forall n \geq 1, R_n = S_n \text{ p.s}$$

VIII.1.3 Détermination de la loi de R_n

On détermine la loi de S_n , dans le cadre des hypothèses données. On note $(N_n^{-1})_{n \in \mathbb{N}}$, le processus qui compte le nombre de divisions différenciées jusqu'à la n-ième division.

On réalise alors le conditionnement suivant :

$$\forall i \geq 1, \quad \mathbb{P}(S_i = n) = \sum_{k=\max(0, 1-n)}^{\lfloor \frac{i-n+1}{2} \rfloor} \mathbb{P}(S_i = n \mid N_i^{-1} = k) \mathbb{P}(N_i^{-1} = k)$$

Pour bien conditionner, il faut dénombrer les valeurs possibles pour k . L'indexation démarre du maximum entre 0 et $1 - n$. En effet elle est minorée par $1 - n$, si on prend le cas où n est négatif. Pour la borne supérieure, il faut pouvoir aboutir à la position n , partant de la position $-k + 1$ (k sauts à gauche), en $n + k - 1$ succès. On recherche donc le plus grand entier tel que $i - k \geq n + k - 1$ qui donne la borne supérieure $\lfloor \frac{i-n+1}{2} \rfloor$.

On remarque que N_i^{-1} compte le nombre de succès (la division est différenciée) au cours de i expérience de Bernoulli indépendante et de même paramètre p_0 . Donc N_i suit une loi binomiale de paramètre i et p_0 . Par ailleurs $(S_i \mid N_i^{-1} = k)$ compte le nombre de succès (la division est symétrique sachant qu'elle n'est pas différenciée) au cours de $i - k$ expériences de Bernoulli indépendante et de même paramètre $\frac{p_2}{p_1 + p_2}$.

On obtient donc :

$$\begin{aligned} \mathbb{P}(N_i^{-1} = k) &= \binom{i}{k} p_0^k (1 - p_0)^{i-k} \\ \mathbb{P}(S_i = n \mid N_i^{-1} = k) &= \binom{i-k}{n+k-1} \frac{p_2}{1-p_0}^{n+k-1} \left(\frac{p_1}{1-p_0} \right)^{i-2k-n+1} \end{aligned}$$

En combinant les deux équations, on aboutit à la loi vérifiée par S_n :

$$\forall i \geq 1, \quad \mathbb{P}(S_i = n) = \sum_{k=\max(0, 1-n)}^{\lfloor \frac{i-n+1}{2} \rfloor} \binom{i}{k} \binom{i-k}{n+k-1} p_0^k p_2^{n+k-1} p_1^{i-2k-n+1} \quad (\text{VIII.VIII.1a})$$

VIII.1.4 Détermination de la loi de T_n

D'après le modèle présenté par Hermange & al. dans [3], on sait déjà que le temps qu'une cellule quelconque HSC met à se diviser suit une loi exponentielle de paramètre α . Le temps qu'il faut pour que la $(n+1)$ -ième division se produise à partir de la n -ième, dépend du nombre de cellules mutées total. En utilisant que la loi exponentielle est sans mémoire, il suffit de considérer la loi associée au minimum des temps mis par chaque cellule pour se diviser à partir de la n -ième division. Ainsi, Le temps qu'il faut pour que la $(n+1)$ -ième division se produise à partir de la n -ième connaissant le nombre total de cellules mutées suit une loi exponentielle de paramètre $R_n \alpha$.

Avec nos notations, cela se traduit par : $D_n \mid S_n$ suit une loi $\mathcal{E}(S_n \alpha)$.

Ainsi, en supposant que T_n admette une densité, on peut écrire :

$$h_{T_n}(t_n) = \int_{t_{n-1}=0}^{t_{n-1}=t_n} h_{T_n \mid T_{n-1}}(t_{n-1}) h_{T_{n-1}}(t_{n-1}) dt_{n-1}$$

Puis en conditionnant par les valeurs de S_n

$$h_{T_n}(t_n) = \sum_{k=-n}^n \int_{t_{n-1}=0}^{t_{n-1}=t_n} h_{(T_n \mid T_{n-1}) \mid (R_n=k)}(t_n, t_{n-1}) \mathbb{P}(R_n = k) h_{T_{n-1}}(t_{n-1}) dt_{n-1}$$

soit encore, en reconnaissant la loi de $D_n \mid S_n$, translatée :

$$h_{T_n}(t_n) = \sum_{k=-n}^n \int_{t_{n-1}=0}^{t_{n-1}=t_n} \mathbb{P}(R_n = k) k \alpha e^{-k \alpha (t_n - t_{n-1})} h_{T_{n-1}}(t_{n-1}) dt_{n-1}$$

Puis en itérant, on obtient la densité de T_n

$$h_{T_n}(t_n) = \sum_{i=2}^n \sum_{k_i=-i}^i \int_{t_{i-1}=0}^{t_{i-1}=t_i} \mathbb{P}(R_i = k_i) k_i \alpha^2 e^{-k_i \alpha (t_i - t_{i-1})} e^{-\alpha t_1} dt_{i-1} \quad (\text{VIII.VIII.1b})$$

VIII.1.5 Détermination de la loi de τ

On suppose que τ admette une densité. On peut alors conditionner la densité par le nombre de divisions qu'il a fallu réaliser pour aboutir au temps τ

$$h_\tau(t) = \sum_{n \geq 1} h_{(\tau, N_\tau=n)}(t)$$

Compte tenu de la définition de τ , cela peut se réécrire

$$h_\tau(t) = \sum_{n=1}^{\infty} h_{\tau, (N_\tau=n), (\bigcap_{i=0}^{n-1} (H_i=0), (H_n=1))}(t)$$

Puis en reconnaissant la loi de T_n

$$h_\tau(t_n) = \sum_{n=1}^{\infty} h_{T_n, N_\tau=n, (\bigcap_{i=0}^{n-1} H_i=0, H_n=1)}(t_n)$$

Ce qui peut se réécrire en utilisant l'hypothèse d'indépendance entre $(H_n)_{n \in \mathbb{N}}$ et T_n :

$$h_\tau(t) = \sum_{n=1}^{\infty} h_{T_n}(t_n) \mathbb{P}\left(\bigcap_{i=0}^{n-1} H_i = 0, H_n = 1\right)$$

ce qui donne en utilisant l'indépendance mutuelle de $(H_n)_{n \in \mathbb{N}}$

$$h_\tau(t) = \sum_{n=1}^{\infty} h_{T_n}(t_n) \gamma(1-\gamma)^{n-1}$$


En conclusion, on peut écrire l'expression explicite de la densité h_{tau}

$$h_\tau(t) = \sum_{n=1}^{\infty} \sum_{i=2}^n \sum_{k_i=-i}^i \int_{t_{i-1}=0}^{t_{i-1}=t_i} \sum_{l=\max(0, 1-i)}^{\lfloor \frac{i-k_i+1}{2} \rfloor} \gamma(1-\gamma)^{n-1} \binom{i}{l} \binom{i-l}{k_i+l-1} p_0^l p_2^{k_i+l-1} p_1^{i-2l-k_i+1} k_i \alpha^2 e^{-k_i \alpha(t_i-t_{i-1})} e^{-\alpha t_1} dt_{i-1} \quad (\text{VIII.VIII.1c})$$

VIII.2 Implémentaiton de la méthode

Dans le modèle présenté par Hermange & al. dans [3], la probabilité p_0 est telle que $p_2 = 0.85p_0$. Ainsi, que la probabilité d'extinction est assez grande, le taux de division différenciées étant de l'ordre de grandeur des deux autres taux de division. On remarque aussi que p_2 est pris plus grand que p_1 . Autrement, la loi faible des grands nombres, donne que le processus s'éteint presque sûrement. Dans l'état actuel, la variable aléatoire S_n tend presque sûrement vers ∞ .

Cette intuition se confirme en traçant la distribution de probabilité de S_n pour $n = 20$.


FIGURE I.17 – Distribution de probabilité de S_{20}

L'extinction est donc trop fréquente pour considérer l'hypothèse (H1).

Une stratégie serait de considérer la variable aléatoire S'_n , définie par :

$$S'_n = S_n I_{S_n \geq 1}$$

qui consiste à considérer la distribution pour laquelle S_n est positive. On obtient la distribution figure I.18. On remarque la probabilité d'extinction est améliorée par $\frac{1}{3}$, car la nouvelle variable aléatoire ne permet pas de localiser la durée du processus. Par exemple, dans le modèle considéré, pour obtenir n cellules mutées, il est possible de faire immédiatement une division différenciée puis n divisions symétriques, ce qui ne revêt aucune réalité biologique car si la première division est progénitrice, le processus s'éteint.

FIGURE I.18 – Distribution de probabilité de S'_{20}

On peut alors calculer la densité de probabilité de T_n , en la calculant comme une suite, de façon récursive. On prend bien soin de ne réaliser qu'un unique appel récursif pour limiter la complexité. L'intégration se calcule avec la fonction 'quad' du module 'Scipy.integrate'. Pour limiter la durée du calcul, on impose une erreur minimale assez grande. L'algorithme utilise une méthode de quadrature en $O(n^2)$, avec n le nombre de subdivision, pour calculer l'intégrale. Cependant les calculs sont très lourds. On obtient la densité suivante pour n allant de 1 à 7 (I.19). La figure montre l'étalement de la densité avec l'augmentation de n . Cela traduit la grande multiplicité des chemins pour aboutir à la $(n+1)$ -ième division et témoigne donc d'une variabilité très grande du modèle dans ses premiers instants. Il faut noter que la densité doit être normalisée, car de l'information est perdue compte tenu de l'approximation $R_n = S_n I_{S_n \geq 1}$. En effet, cela ne présente pas de sens de dire que lorsque 0 cellule sont présentes, le temps de la prochaine division suit une loi exponentielle de paramètre (0α) . On remarque qu'à chaque intégration, on perd environ 33% de l'information, ce qui est cohérent avec la distribution de S'_n I.18. On se permet alors de renormaliser la densité à chaque itération.




FIGURE I.19 – Distribution de probabilité de S'_{20}

Enfin, le calcul de la densité du temps d'arrêt n'a pas pu être mis en oeuvre car il n'était pas possible d'aller au-delà de $n = 7$, en temps de calcul.

IX Troisième approche : détermination du temps de première apparition d'une cellule homozygote via un modèle de branchement

Le but de cette partie est de modéliser le temps d'apparition des cellules homozygotes par une troisième approche. Pour ce faire, nous commençons par introduire les processus de branchement, ainsi que des résultats importants sur les fonctions génératrices de moments qui vont nous être utiles pour la suite. Ensuite, nous modéliserons notre situation à l'aide de processus de branchements, et mettrons en équation le problème. Finalement, nous résoudrons ces équations et qui pourront nous donner la probabilité du temps d'apparition des cellules homozygotes.

IX.1 Explication du fonctionnement des processus de branchements

Nous reprenons ici dans les grandes lignes ce qui a été dit dans [4]. Le lecteur intéressé pourra donc le lire. Un processus de branchement est une famille de variables aléatoires non nulles $\{Z(t, \omega), t \geq 0\}$. Ces variables aléatoires représentent le nombre de particules à l'instant t étant donné une trajectoire ω . Elles permettent de modéliser la dynamique des divisions cellulaires. À l'instant $t = 0$, on dispose d'une unique cellule, qui a son propre processus de branchement, qui va décrire l'évolution cellulaire avec elle comme première cellule. En

introduisant une variable aléatoire $\tau(\omega)$, représentant l'instant où la cellule meurt, et sous l'hypothèse que lors de la mort de la cellule, celle-ci se divise en $X(\omega)$ cellules filles, on peut écrire la relation suivante :

$$Z(t, \omega) = \begin{cases} \sum_{k=0}^{X(\omega)} Z^{(k)}(t, \tau(\omega), \omega), & t \geq \tau(\omega) \\ 1, & t < \tau(\omega) \end{cases}$$

où $Z(t, \tau(\omega), \omega)$ représente le nombre de cellules en partant d'une cellule fille de la première cellule mère, et qui commence donc à l'instant $\tau(\omega)$ (à la mort de la cellule mère). Cependant, les variables aléatoires $Z(t)$ ont une propriété particulière que l'on va leur attribuer, la propriété de branchement, qui dit simplement que la loi d'évolution des processus de branchements des cellules filles sont de même loi et indépendants que celui de la cellule mère, ou encore, bien-sûr pour $t \geq \tau(\omega)$:

$$Z(t, \tau(\omega), \omega) = Z(t - \tau(\omega), \omega)$$

Ceci donne dans notre première formule :

$$Z(t, \omega) = \begin{cases} \sum_{k=0}^{X(\omega)} Z^{(k)}(t - \tau(\omega), \omega), & t \geq \tau(\omega) \\ 1, & t < \tau(\omega) \end{cases}$$

IX.2 Résultats sur les fonctions génératrices de moments

Cette section est très brève, mais rappelle des résultats essentiels sur les fonctions génératrices de moments (fgm), que l'on utilisera plus tard et avec lesquelles nous allons beaucoup travailler. Nous commençons par rappeler la définition de la fgm :

Définition 1. Soit X une variable aléatoire à valeurs dans $\mathbb{N}$. Sa fgm f_X est définie par :

$$f_X(s) = \mathbb{E}(s^X) = \sum_{k=0}^{+\infty} \mathbb{P}(X = k) s^k$$

Nous rappelons ensuite le résultat suivant :

Theorem 1. Si Y est une variable aléatoire dans $\mathbb{N}$, et $\{X^{(i)}\}$ une suite de variables aléatoires indépendantes identiquement distribuées à valeurs dans $\mathbb{N}$, toutes indépendantes de Y , alors $V = \sum_{i=0}^Y X^{(i)}$ a pour fgm $f_V(s) = f_Y(f_{X^{(1)}}(s))$

IX.3 Application des processus de branchement à notre cas d'utilisation

Il s'agit ici de détailler l'adaptation des modèles de branchement à notre cas : à savoir modéliser l'apparition de cellules homozygotes. Pour ce faire, nous allons d'abord mettre en place le cadre de travail, avant de passer à la modélisation en termes d'équations et de les résoudre.

IX.3.1 Cadre de travail

Nous avons assimilés l'évolution des cellules grâce à un processus de branchement. Les cellules peuvent appartenir à trois catégories différentes :

- La catégorie 0 : celle des cellules hétérozygotes
- La catégorie 1 : celle des cellules homozygotes
- La catégorie 2 : celle des cellules différenciées

Nous partons d'une cellule hétérozygote à l'instant $t = 0$. Lors de sa mort, celle-ci va pouvoir se diviser en deux cellules, qui vont à leur tour appartenir à la catégorie 0, 1 ou 2 avec des probabilités différentes, et qui vont à leur tour se diviser. La figure suivante énumère tous les cas de figure considérés pour les divisions cellulaires avec les probabilités associées, en fonction de la cellule mère.

Par ailleurs, le temps de division cellulaire τ est considéré comme suivant une loi exponentielle de paramètre λ .




FIGURE I.20 – Illustration de la situation

IX.3.2 Présentation des notations et mise en équation

Nous noterons par la suite :

- $F_0(s_0, s_1, s_2, t)$ la fgm jointe du nombre de cellules appartenant aux trois catégories, définie par : $F_0(s_0, s_1, s_2, t) = \mathbb{E}(s_0^{Z_0(t)} s_1^{Z_1(t)} s_2^{Z_2(t)})$
- $F_1(s_1, s_2, t)$ la fgm jointe du nombre de cellules appartenant aux catégories 1 et 2.
- $F_2(s_2, t)$, la fgm du nombre de cellules appartenant à la catégorie 2.

D'après le calcul mené par [4], et en notant $F = [F_0, F_1, F_2]$, nous avons l'équation suivante :

$$\frac{dF}{dt}(s, t) = -\lambda[F(s, t) - f(F(s, t))]$$

Or on a :

$$\begin{cases} f_0(s) = \alpha_{00}s_0^2 + \alpha_{10}s_0s_1 + \alpha_{11}s_1^2 + \alpha_{02}s_0s_2 + \alpha_{12}s_1s_2 + \alpha_{22}s_2^2 \\ f_1(s) = \beta_{11}s_1^2 + \beta_{12}s_1s_2 + \beta_{22}s_2^2 \\ f_2(s) = s_2 \end{cases}$$

Ceci nous donne le système suivant :

$$\begin{cases} \frac{dF_0}{dt} = -\lambda F_0 + f_0(F_0, F_1, F_2) \\ \frac{dF_1}{dt} = -\lambda F_1 + f_1(F_1, F_2) \\ \frac{dF_2}{dt} = 0 \end{cases}$$

IX.3.3 Etude mathématique de la solution à notre problème

En résolvant le système ci-dessus, nous pouvons en particulier obtenir la fonction F_0 . Nous pouvons l'écrire de la manière suivante :

$$F_0(s, t) = \mathbb{E}(s_0^{Z_0(t)} s_1^{Z_1(t)} s_2^{Z_2(t)}) = \sum_{i=0}^{+\infty} \sum_{j=0}^{+\infty} \sum_{k=0}^{+\infty} \mathbb{P}(Z_0(t) = i, Z_1(t) = j, Z_2(t) = k) s_0^i s_1^j s_2^k$$

Ceci peut ainsi se réécrire de la manière suivante :

$$F_0(s, t) = \sum_{i=0}^{+\infty} \mathbb{P}(Z_0(t) = i, Z_1(t) = 0, Z_2(t) = 0) + s_1 s_2 \sum_{i=0}^{+\infty} \sum_{j=1}^{+\infty} \sum_{k=1}^{+\infty} \mathbb{P}(Z_0(t) = i, Z_1(t) = j, Z_2(t) = k) s_0^i s_1^{j-1} s_2^{k-1}$$

En passant à la limite quand $s_1 \rightarrow 0, s_2 \rightarrow 0$, et $s_0 \rightarrow 1$:

$$\lim_{\substack{s_0 \rightarrow 1 \\ s_1 \rightarrow 0 \\ s_2 \rightarrow 0}} F_0(s, t) = \mathbb{P}(Z_0(t) \in \mathbb{N}, Z_1(t) = 0, Z_2(t) = 0)$$

Ceci correspond à la probabilité de ne pas avoir eu de mutations avant l'instant t . En prenant cette fois $s_2 \rightarrow 1$, on obtient :

$$\lim_{\substack{s_0 \rightarrow 1 \\ s_1 \rightarrow 0 \\ s_2 \rightarrow 1}} F_0(s, t) = \mathbb{P}(Z_0(t) \in \mathbb{N}, Z_1(t) = 0, Z_2(t) \in \mathbb{N})$$

Cette formule est beaucoup plus adaptée à ce que nous recherchons. Elle correspond à la probabilité de ne pas avoir de cellules homozygotes avant l'instant t . Nous voulons cependant chercher à déterminer la loi du temps d'apparition des k premières cellules, ce qui veut dire que nous avons besoin de connaître :

$$(p_k(t))_{k \in \mathbb{N}} = (\mathbb{P}(Z_0(t) \in \mathbb{N}, Z_1(t) = k, Z_2(t) \in \mathbb{N}))_{k \in \mathbb{N}}$$

En effet, ceci correspond à la probabilité d'avoir obtenu moins de k cellules homozygotes avant l'instant t . Une approche consisterait à calculer de manière itérative les probabilités pour différentes valeurs de k . Par exemple, pour p_1 , puisque l'on connaît déjà p_0 :

$$F_0(s, t) - p_0 = s_1 \sum_{i=0}^{+\infty} \sum_{j=1}^{+\infty} \sum_{k=0}^{+\infty} \mathbb{P}(Z_0(t) = i, Z_1(t) = j, Z_2(t) = k) s_0^i s_1^{j-1} s_2^k$$

Ceci donne :

$$\frac{F_0(s, t) - p_0}{s_1} = p_1 + s_1 \sum_{i=0}^{+\infty} \sum_{j=2}^{+\infty} \sum_{k=0}^{+\infty} \mathbb{P}(Z_0(t) = i, Z_1(t) = j, Z_2(t) = k) s_0^i s_1^{j-2} s_2^k$$

En prenant la limite lorsque $s_0 \rightarrow 1, s_1 \rightarrow 0, s_2 \rightarrow 1$, on obtient p_1 :

$$\lim_{\substack{s_0 \rightarrow 1 \\ s_1 \rightarrow 0 \\ s_2 \rightarrow 1}} \frac{F_0(s, t) - p_0}{s_1} = p_1$$

Nous pouvons itérer la méthode ci-dessus afin de trouver toutes les probabilités $(p_k)_{k \in \mathbb{N}}$. On peut ainsi entièrement déterminer la loi cherchée.

IX.3.4 Résolution du système

Ce système n'admet pas de solutions évidentes. Nous avons donc implémenté un script Python utilisant la fonction `odeint` du module `scipy.integrate` afin de pouvoir approcher la solution. Nous avons ainsi obtenu la courbe suivante pour la fonction F_0 , et avons prit comme conditions initiales $s_0 = 1, s_1 = 0, s_2 = 0$:

On peut ainsi déterminer la fonction de partition :

Nous n'avons pas eu le temps de bien finir d'implémenter le modèle, nous avons donc seulement utilisés la probabilité obtenue à la figure ci-dessus pour déterminer les temps d'apparition des différentes cellules homozygotes. Nous avons procédé de la manière suivante :

1. On détermine $P(t)$ qui correspond à la première partie de la liste renvoyée par la fonction *odeint* (le premier élément de chaque liste dans la liste), ce qui nous donne une liste d'éléments ordonnés dans l'ordre croissant L .
2. On obtient sa fonction de partition (figure I.21)
3. On tire aléatoirement un nombre n entre 0 et 1 avec le module random de python.
4. On regarde l'indice du premier élément de la liste L qui est supérieur ou égal à n
5. On obtient le temps associé (on regarde l'élément de la liste des temps fournie à la fonction *odeint* dont l'indice est celui déterminé dans l'étape précédente), et on stocke la valeur obtenue dans une liste.
6. On répète les étapes 3 à 5 autant de fois que l'on veut faire apparaître de cellules homozygotes




FIGURE I.21 – Fonction de partition du temps de première apparition

Ceci nous permet d'obtenir l'ensemble de l'information dont nous avons besoin pour pouvoir répondre à notre problème

IX.4 Pistes d'améliorations pour cette modélisation

Nous avons fait une première approximation des différents temps d'apparition des cellules homozygote. Il reste à implémenter la partie mathématique de manière informatique afin de pouvoir obtenir des résultats plus proches de ce que nous recherchons. On pourrait également s'intéresser à une formulation semi-explicite de la solution à notre système obtenue via la modélisation. Ceci nous permettrait d'avoir une plus grande rapidité dans nos calculs, et on pourrait peut-être même en dire plus sur la forme de nos solutions pour les $(p_k)_{k \in \mathbb{N}}$

X Conclusion et perspectives

Afin d'améliorer le modèle initial, nous avons incorporé les cellules homozygotes au modèle, ne considérant autrefois que les cellules hétérozygotes.

Dans le processus de simulation il nous a été nécessaire de déterminer la loi de l'apparition des k premières cellules homozygotes. Pour cela 3 approches différentes ont été envisagées, chacune d'entre elles ayant ses avantages et ses inconvénients comme présenté dans les sections associées.

La prochaine étape consisterait en la réussite de l'implémentation d'une loi d'apparition des premières cellules homozygotes qui pourrait être calculée en un temps raisonnable. Une fois celle-ci incorporée au modèle, une estimation des paramètres du modèle serait rendue possible en utilisant les données patients de l'article de Williams&al.[7].




FIGURE I.22 – Densité du temps de première apparition

Bibliographie

- [1] Anna L. Godfrey, Edwin Chen, Francesca Pagano, Christina A. Ortmann, Yvonne Silber, Beatriz Bellosillo, Paola Guglielmelli, Claire N. Harrison, John T. Reilly, Frank Stegelmann, Fontanet Bijou, Eric Lippert, Mary F. McMullin, Jean-Michel Boiron, Konstanze Döhner, Alessandro M. Vannucchi, Carlos Besses, Peter J. Campbell, and Anthony R. Green. JAK2v617f homozygosity arises commonly and recurrently in PV and ET, but PV is characterized by expansion of a dominant homozygous subclone. *Blood*, 120(13) :2704–2707, September 2012.
- [2] S Hasan, B Cassinat, N Droin, J P Le Couedic, F Favale, B Monte-Mor, C Lacout, M Fontenay, C Dosquet, C Chomienne, E Solary, J L Villeval, N Casadevall, J J Kiladjian, W Vainchenker, and I Plo. Use of the 46/1 haplotype to model JAK2v617f clonal architecture in PV patients : clonal evolution and impact of IFN treatment. *Leukemia*, 28(2) :460–463, October 2013.
- [3] Gurvan Hermange, Alicia Rakotonirainy, Mahmoud Bentrion, Amandine Tisserand, Mira El-Khoury, François Girodon, Christophe Marzac, William Vainchenker, Isabelle Plo, and Paul-Henry Cournède. Inferring the initiation and development of myeloproliferative neoplasms. *Proceedings of the National Academy of Sciences*, 119(37) :e2120374119, 2022.
- [4] David E. Axelrod Marek Kimmel. Branching processes in biology.
- [5] I. Matic. Dna mismatch repair and homologous recombination. In William J. Lennarz and M. Daniel Lane, editors, *Encyclopedia of Biological Chemistry (Second Edition)*, pages 45–50. Academic Press, Waltham, second edition edition, 2013.
- [6] Wikipedia. Mitotic recombination — Wikipedia, the free encyclopedia. <http://en.wikipedia.org/w/index.php?title=Mitotic%20recombination&oldid=1106302193>, 2023. [Online; accessed 22-January-2023].
- [7] Nicholas Williams, Joe Lee, Emily Mitchell, Luiza Moore, E Joanna Baxter, James Hewinson, Kevin J Dawson, Andrew Menzies, Anna L Godfrey, Anthony R Green, et al. Life histories of myeloproliferative neoplasms inferred from phylogenies. *Nature*, 602(7895) :162–168, 2022.